WEBINAIRE

GESTION DE LA CONFIGURATION ET DES RÉSULTATS AVEC MLFLOW/ WEIGHTS AND BIASES, HYDRA ET POUTYNE

3 MAI 2022

OBJECTIFS DE LA PRÉSENTATION

- Initier aux outils de gestion de la configuration et des résultats.
- Développer de bonnes pratiques.
- · Améliorer votre productivité.

VOTRE CONFÉRENCIER



DAVID BEAUCHEMIN
Candidat au doctorat
Département d'informatique et de génie logiciel

- Introduit à la recherche reproductible en 2016 (R Markdown et git)
- Participation à REPROLANG de la conférence LREC [Garneau et al., 2020]

AU MENU



Gestion de la configuration



Gestion des résultats

La gestion d'un projet

```
001
        @experiment.config
        def config():
002
          seed = 42
003
004
          num runs = 10
          iteration = 0
005
          source_language = "en"
006
007
          target language = "de"
008
          src_input = "path" # The input source embeddings
          trg input = "2e path" # The input target embeddings
009
010
          other input = "3e path" # Commentaire pas clair
```

n^e paramètre

395

Lequel fait ça déjà?

Lesquels vont Lequel fait ça déjà? nécessairement ensemble?

Lequel fait ça déjà?

Lesquels vont nécessairement ensemble?

Lesquels sont vraiment essentiels?

Lesquels vont Lequel fait ça déjà? nécessairement ensemble?

Lesquels sont vraiment essentiels?

Comment les organiser?

```
res_1.txt
res_2.txt
res_3.txt
res 4.txt
res_5_good.txt
res_5.txt
res_6_fix_a.txt
_ne fichier de résultats
```

Quelle configuration (déjà) utilisée?

Quelle configuration (déjà) utilisée?

Succès ou échec?

Quelle configuration (déjà) utilisée?

Succès ou échec?

Lequel est le meilleur?

Quelle configuration (déjà) utilisée?

Succès ou échec?

Lequel est le meilleur?

Comment les organiser?



AU MENU



Gestion de la configuration



Gestion des résultats

GESTION DE LA CONFIGURATION



Simple et efficace

GESTION DE LA CONFIGURATION



Simple et efficace



Facilite l'expérimentation

GESTION DE LA CONFIGURATION









Extensible

SOLUTIONS POSSIBLE

- Arguments (e.g. argsparse, configparser)
- Fichier texte
- JSON
- YAML
- . . .

HYDRA ♂*



Open source et licence MIT



Fichiers de configurations structurés YAML



Fichiers de configurations hiérarchiques



Balayage de configurations

CONFIGURATION STRUCTURÉ

patience: 30

```
data_loader:
  batch_size: 2048
setting:
  seed:42
  device: "cuda:0"
defaults:
  - optimizer: SGD
  - model: bi lstm
  - dataset : canadian
  - embeddings : fast_text
trainer:
  num epochs:1
```

| CONFIGURATION HIERARCHIQUE |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre>conf config.yaml dataset canadian.yaml netherlands.yaml embeddings fast_text.yaml model bi_lstm_bidirectionnal.yaml bi_lstm.yaml lstm_bidirectionnal.yaml clstm.yaml stm.yaml coptimizer adam.yaml SGD.yaml</pre> |
| 30D. yame |

CONFIGURATION HIÉRARCHIQUE

optimizer: SGD

optimizer:

Ir: 0.1 type:sgd

EXEMPLE

```
@hydra.main(config_path='conf/config.yaml')
def main(cfg):
  Ir = cfg.optimizer.Ir #0.1
```

BALAYAGE DE CONFIGURATIONS

python main.py -multirun task=1,2,3,4,5

python main.py -m 'main.x=int(interval(-5, 5))' 'main.y=interval(-5, 10)'

EN BONUS

- Journalisation automatique et personnalisable
- Instanciation paramétrique

```
model:
_target_: models.LSTMNetwork
hidden_state_dim:300
num_hidden_layer:2
dropout:0.4
```

EXEMPLE

```
log = logging.getLogger(__name__)
@hydra.main(config_path='conf/config.yaml')
def main(cfg):
    log.info("Init of the trainning")
    :
    network = instantiate(cfg.model)
```

POINT NÉGATIF

hydra.utils.get_original_cwd()

AU MENU



Gestion de la configuration



Gestion des résultats



Simple à utiliser





Journalisation des expérimentations





expérimentations



Visualisation rapide des expérimentations

MLFLOW TRACKING **□****



Open source et licence Apache 2.0



Journalisation automatique



Visualisation simple



Intégration avec Poutyne

JOURNALISATION AUTOMATIQUE

- Version du code (git)*
- Horodatage de l'entrainement
- Succès/échec de l'entrainement
- Configuration de l'ordinateur
- Utilisateur

mlflow server -p 5000 -h 127.0.0.1 -backend-store-uri file:///absolute/path

| mlflow | | | | | | | | | |
|-----------------------------------------------------------------------|-------|---------------------------------|-----------|---------|-------|-------------|-------|---------|--------|
| Listing Price Prediction | | | | | | | | | |
| Experiment ID: 0 Artifact Location: /Users/matei/mlflow/demo/mlruns/0 | | | | | | | | | |
| Search Runs: | | metrics.R2 > 0.24 | | | | | | | Search |
| Filter Params: | | alpha, Ir Filte | | | | s: rmse, r2 | Clear | | |
| 4 matching runs | | Compare Selected Download CSV & | | | | | | | |
| | | | | | Pa | arameters | | Metrics | |
| | Time | User | Source | Version | alpha | I1_ratio | MAE | R2 | RMSE |
| | 17:37 | matei | linear.py | 3a1995 | 0.5 | 0.2 | 84.27 | 0.277 | 158.1 |
| | 17:37 | matei | linear.py | 3a1995 | 0.2 | 0.5 | 84.08 | 0.264 | 159.6 |
| | 17:37 | matei | linear.py | 3a1995 | 0.5 | 0.5 | 84.12 | 0.272 | 158.6 |
| | 17:37 | matei | linear.py | 3a1995 | 0 | 0 | 84.49 | 0.249 | 161.2 |

Figure 1: Introducing MLflow: an Open Source Machine Learning Platform ♂*

- Tri sur les expérimentations
- Recherche des expérimentations
- Requêtes sur les résultats
- Exportation des résultats
- Visualisation des métriques

INTÉGRATION AVEC POUTYNE **

La version de « base » implique de journaliser manuellement

- les paramètres de configuration,
- les métriques à chaque étape et itération,
- la version du code.

INTÉGRATION AVEC POUTYNE 2*

La solution, MLFlowLogger, un callback permettant de journaliser

- semi-automatiquement les paramètres de configuration,
- automatiquement les métriques à chaque étape et itération,
- automatiquement la version du code,
- automatiquement les métriques de test lors d'une phase de test.

EXEMPLE

```
@hydra.main(config_path='conf/config.yaml')
def main(cfg):
    :
    mlflow_logger = MLFlowLogger(experiment_name="experiment")
    mlflow_logger.log_config_params(config_params=cfg)
```

POINT NÉGATIF

- La documentation n'est pas toujours facile à naviguer, et
- très complexe de journaliser des artefacts, nous n'avons pas réussis.

WEIGHTS & BIASES ☑**



Journalisation automatique



Visualisation simple et puissante



Génération de graphique automatique



Intégration avec Poutyne

JOURNALISATION AUTOMATIQUE

- Version du code (git)
- Horodatage de l'entrainement
- Succès/échec de l'entrainement
- · Configuration de l'ordinateur
- Utilisateur
- Génération automatique de graphique
- Journalisation des artefacts et sweeps

wandb local

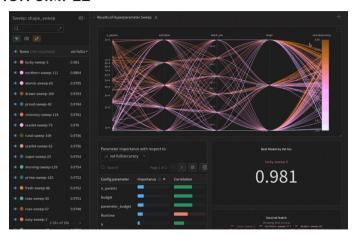


Figure 2 : Demo **∠****

- Tri sur les expérimentations
- Recherche des expérimentations
- Requêtes sur les résultats
- Exportation des résultats
- Visualisation des métriques
- Interface avec **beaucoup** d'informations

INTÉGRATION AVEC POUTYNE **

La version de « base » implique de journaliser manuellement

- les paramètres de configuration,
- les métriques à chaque étape et itération,
- · la version du code,
- · les artefacts.

INTÉGRATION AVEC POUTYNE **

La solution, WandbLogger, un callback permettant de journaliser

- semi-automatiquement les paramètres de configuration,
- automatiquement les métriques à chaque étape et itération,
- · automatiquement la version du code,
- · automatiquement un modèle,
- automatiquement les métriques de test lors d'une phase de test, et
- manuellement des images et figures.

EXEMPLE

```
@hydra.main(config_path='conf/config.yaml')
def main(cfg):
    :
    wandb_logger = WandB(name="experiment", project="A project")
    wandb_logger.log_config_params(config_params=cfg)
    :
    image = wandb.lmage('a/image.png', caption="a caption")
    wandb_logger.run.log("My image": image)
```

POINT NÉGATIF

Solution propriétaire (gratuit académique 40\$/mois utilisateur sinon).



PRÉSENTATION DES RÉSULTATS



Génération automatique des tableaux



Rapport dynamique



Itérations d'expérimentations

POUR ALLER PLUS LOIN (EN ORDRE)

- Notification de l'état d'entrainement Notif 💤
- Continuous Machine Learning (CML) ♂*

PÉRIODE DE QUESTIONS



WEBINAIRE

MERCI DE VOTRE ÉCOUTE!

REFERENCES i



Garneau, N., Godbout, M., Beauchemin, D., Durand, A., and Lamontagne, L. (2020).

A Robust Self-Learning Method for Fully Unsupervised Cross-Lingual Mappings of Word Embeddings: Making the Method Robustly Reproducible as Well.